

## Аналитическая записка

### Принятые допущения, сознательно опущенные моменты и т.п.

- При решении задачи возникало множество вопросов об особенностях радарных профилей и о предобработке, выполняемой на радаре. На данном этапе я ограничилась доступной мне информацией и своими предположениями, однако в реальной ситуации на этом шаге должна была бы быть подробная консультация с коллегами.
- В процессе предварительного анализа были найдены записи:
  - с отсутствующим радарным профилем (**num\_profile** содержит NaN);
  - с одинаковым идентификатором судна, но различными габаритами. Поскольку габариты в датасете явно взяты из внешнего источника, а не рассчитаны на основе данных радара (и в большинстве случаев значения габаритов в записях, соответствующих одному **ais\_id**, одинаковы), я сочла такие записи некорректными;
  - с типом судна *fishery\_research vessel*, который встречается в датасете всего один раз, и этого явно не достаточно для идентификации судов данного класса.**Такие записи были исключены из рассмотрения.**
- Также в данных присутствует **класс судна None**. Не стала удалять такие записи. Но если это не один из типов, а неизвестный тип, то такие записи следует удалять.
- При построении модели и формировании признаков я предполагала, что числовые значения, составляющие радарный профиль, представляют из себя амплитуды отраженных сигналов и находятся в некоторой зависимости от расстояний от радара до объекта (и от курсового угла), а также связаны с относительными размерами частей судна, однако эти зависимости неоднозначны, и на результирующие значения могут оказывать влияние множественные отражения сигнала и шумы.
- Поскольку я предположила, что опираться на абсолютные значения амплитуд может быть не совсем корректно (что подтверждается графиками профилей одного и того же корабля под разными углами и на разных расстояниях от радара), то произвела масштабирование радарного профиля на отрезок [0,1] пообъектно. Таким образом, некоторые признаки используют информацию об относительных величинах пиков радарных профилей вместо абсолютных.
- Поскольку радарный профиль изначально зашумлен, скорее всего, необходима фильтрация получаемого сигнала. Возможно, она производится на радаре, а в датасете содержится уже очищенный сигнал. В рамках данного исследования фильтрация сигнала мною не производилась.
- При построении модели была обнаружена сильная зависимость между расстоянием от судна до радара и целевой меткой (**marine\_traffic\_class**). Я построила модель, которая принимает на вход только два параметра — **distance\_to\_radar** и **view\_angle**. У такой модели получилась точность около 65%. Определение типа судна на основе данных параметров, конечно, смысла не имеет, поскольку данные значения не являются характеристиками исследуемых объектов — судов. Высокую значимость признака

***distance\_to\_radar*** можно объяснить особенностями собранного набора данных — возможно, суда разных типов чаще всего наблюдались на определенных диапазонах расстояний до радара. Из этого я сделала вывод, что признак ***distance\_to\_radar*** хоть и может быть полезен при построении классификаторов, однако использовать его напрямую не стоит во избежание потери обобщающей способности моделью. Можно пробовать включать его косвенно — например, при расчете новых комбинированных признаков, или, может быть, для оценки априорного распределения вероятностей классов (если это нужно, и если появление кораблей разных типов в разных местах акватории не совсем случайно, а может быть каким-то образом обосновано). По указанным причинам в рамках данного исследования признак ***distance\_to\_radar*** исключен несмотря на то, что добавление его в модель дает существенную прибавку точности моделей.

## Состав и описание решения

eda.ipynb — разведочный анализ данных  
features\_creation.ipynb — работа с признаками  
modeling.ipynb — моделирование

**Признаки** (подробнее — в коде):

- Исходные радарные профили
- Нормализованные радарные профили
- Значения и индексы пиков, их ранжирование по убыванию
- Соотношения между пиками
- Количество пиков
- Диапазон значений пиков
- Нулевой начальный момент
- Первый начальный момент
- Центр тяжести и относительное положение центра тяжести
- Второй и третий центральные моменты
- Нормированные центральные моменты
- skewness, kurtosis, медиана

Было подготовлено два датасета — с масштабированием профиля и без.

Не все признаки вошли в модели - некоторые из них ухудшали качество моделей или не давали прироста качества, некоторые были исключены, по причине высокой корреляции с другими использованными признаками.

**Для прогнозирования типа судна приведено две модели:**

1) RandomForestClassifier показал accuracy 61,73%

Использован датасет без масштабирования.

2) Нейронная сеть показала accuracy **72,17%**

Использован датасет без масштабированием.

Архитектура нейронной сети:

- полносвязный слой из 218 нейронов с активацией tanh и инициализацией весов glorot-uniform

- слой батч-нормализации
- полносвязный слой из 436 нейронов с активацией ReLU и инициализацией весов Хе
- слой батч-нормализации
- выходной слой с 33 нейронами и активацией софтмакс

**Для прогнозирования габаритного класса приведена модель**

RandomForestClassifier, которая показала accuracy **77,87%**

## **Пути для улучшения моделей**

- Увеличить количество примеров классов, в которых в текущем датасете мало объектов, путем сбора дополнительных данных, либо путем семплирования (например, с помощью простого oversampling или SMOTE).  
В результате анализа произведенного решения выявились некоторые классы, которые совершенно не распознаются. Это как раз классы с малым количеством примеров. Также следует отдельно их проанализировать и поискать новые признаки, которые позволили бы выделить данные типы судов среди остальных.
- Подобрать архитектуру нейронной сети, которая больше подходит для данной задачи. Например, RBF (радиально-базисные НС)
- Поработать с распределениями признаков. Возможно, некоторые признаки следует прологарифмировать или иным образом обработать.
- Составить новые признаки, в т.ч. использовать расстояние до радара и угол при расчете признаков.
- Использовать фильтрацию для отсекаания шумов
- Тщательнее настроить гиперпараметры, использовать кросс-валидацию

И т.д.